

선택분야	분야3 ✓ 규제 대응 및 지능형 임상 설계	팀 명	mandu5	에이전트명	먹줄 (INKLINE)
키워드 국문	규제과학 에이전트 · 구조 유래 조항 · 템플릿 증분 평가 · 선택적 발행(기권) · 근거 추적 감사				
키워드 영문	regulatory-science agent · structure-to-clause · template-increment evaluation · selective issuance · auditable provenance				

요약 이 프로토콜의 조항 중, 이 분자 때문에 들어간 것은 몇 개입니까?

국내 바이오텍은 임상 프로토콜을 유사 시험 템플릿에서 복제해 쓴다. 그 결과 **이 분자에 고유한 위험이 조항으로 번역되지 않고**, 나중에 프로토콜 수정으로 청구된다(실질적 수정 1건 직접비 중앙값 2상 US\$141,000·3상 US\$535,000). **먹줄(INKLINE)**은 SMILES에서 구조 위험을 연역해 프로토콜 조항을 제안하되, **템플릿에 이미 있는 조항과 이 분자 때문에 필요한 조항을 데이터로 분리**하고, 구조 귀속이 입증되지 않으면 **기권**하는 5-에이전트 규제과학 시스템이다. 주장으로 끝내지 않았다. 실제 임상시험 **39,379건**의 선정·제외기준 원문으로 검정했고, **결과를 보기 전에 선언한** 기전 가설 26쌍 중 **8쌍만** **확증**되고 15쌍이 기각됐다. 티오펜의 반응성 대사체→간독성은 **반대 방향으로** 유의했다(lift 0.57). 에이전트도 이미 돌아가며 **3회 반복 실행 시 감사 DAG 해시가 일치**한다.

그래서 이 시스템이 필요하다. 구조 경보를 그대로 조항으로 번역하는 규칙 엔진은 템플릿보다 **오히려 나뉘었다**($\Delta\text{AUPRC} -0.086$). 주지표 $\text{FOR}_{\text{safety}}$ 는 **1.28%**(목표 2% 이하) 통과, 확증 경보 없는 3,274쌍의 발행은 **0건**이었다.

구조 경보	프로토콜 조항	lift	종양 / 비종양	Fisher p
친유성 ($\text{cLogP} \geq 3.7$)	음식·자몽 제한	1.91	2.49 / 1.77	3e-31
방향족 할로겐	음식·자몽 제한	1.89	2.48 / 1.71	2e-27
방향족 할로겐	CYP·약물상호작용	1.83	2.13 / 1.62	5e-87
친유성 ($\text{cLogP} \geq 3.7$)	CYP·약물상호작용	1.78	2.01 / 1.54	2e-87
카복실산	위장관 궤양 병력	1.54	1.15 / 1.85	4e-18
하이드라진	간기능	1.39	1.26 / 1.56	1e-4

확증 8쌍 중 상위 6. 적응증 총화 후에도 양쪽에서 방향이 유지된 것만 남겼다 (실제 임상시험 39,379건, 사전 선언 26쌍 중 확증률 34.8%).

재현: `prototype/trialbench/fetch.sh` → `s2c_analysis.py`. 원자료는 TrialBench (Nature Sci Data 2025, ClinicalTrials.gov 기반 공개 데이터).

1 신약개발에서의 에이전트 활용의 필요성과 배경

프로토콜 조항이 분자 구조를 반영하지 않아, 나중에 돈으로 고친다.

■ 어느 지점의 문제인가

비임상 종료부터 IND 제출, 1/2상 프로토콜 확정까지의 구간이다. 사용자는 **국내 중소 바이오텍의 RA·임상개발 담당자 1~2명**이며, AI 전담 인력이 없고 폐쇄망에서 일한다. 국내 RA 인력난은 대형 제약사보다 중소 바이오기업이 훨씬 크게 체감한다고 보고된다.

이들은 프로토콜을 백지에서 쓰지 않는다. 같은 적응증·같은 상의 기존 시험에서 기준을 가져와 고친다. 효율적이지만 **이 분자에만 있는 위험이 조항으로 번역될 경로가 없다**. 누락은 프로토콜 수정·IND 보완·개시 지연으로 청구된다.

■ 조항의 절반은 분자와 무관하다 — 실측

임상시험 39,379건의 선정·제외기준 원문에서 조항 유형별 출현율을 측정했다. 이 분포가 문제의 성격을 바꾼다.

조항 유형	기저 출현율	해석
피임 요구	38.3%	가임 대상 시험의 관례적 포함 → 분자 귀속 주장에서 제외
간기능 수치 기반 제외	36.3%	사실상 템플릿. 증분 없이는 가치 없음
QT·심전도	19.7%	절반 이하 → 구조 신호가 잡히는 구간
CYP·약물상호작용	10.9%	가장 선별적. lift 1.8 확보
광과민성	0.9%	희소 → 검정력 부족으로 판정 오류 선언

문제는 조항을 더 넣는 것이 아니라, 어느 조항이 이 분자 때문인지 가려내는 것이다.

■ 왜 LLM 단독으로는 안 되는가

프론티어 모델의 실제 계산생물 워크플로 open-answer 정확도는 **17%**이고 (BixBench), 동일 문항을 순차 의사결정 형식으로 바꾸면 정확도가 크게 붕괴한다(AgentClinic). 인용 출처 지목 정확도는 LM **4.2~18.5%** 대 인간 **69.7%**이다(CiteME). **규제 문서에서 숫자와 판정을 LLM 손에서 빼앗는 구조**가 요구된다.

기존 시스템도 이 자리를 비워두고 있다. TrialGPT는 환자↔시험 매칭이고, AMEND++는 '수정될 것인가'를 맞히는 이진 예측이다. **어느 조항을 무엇 때문에 넣어야 하는지 분자 구조에서 연역하는 공개 시스템은 없다**.

■ 왜 지금인가

식약처는 2026년부터 허가 심사에 AI를 도입하고, FDA는 2025년 1월 draft guidance에서 **Context of Use와 model risk** 기반 7단계 신뢰성 평가를

제시했다. 그런데 이 프레임은 전부 결정론적 '모델'을 전제한다. **실행마다 도구 호출 경로가 달라지는 멀티에이전트의 COU 정의와 재현성 입증은 규정 공백**이다. 먹줄은 그 공백을 문서가 아니라 실물(COU 카드·감사 DAG·재현성 봉인)로 채운다.

2 에이전트 설계 및 설계의 독창성과 창의성

설계 원리는 셋이다. **P1 결정론 코어/확률론 주변부** — 모든 수치·구조 판정은 결정론 도구가 낸다. **P2 템플릿 분리** — 모든 조항은 발행 시점에 템플릿/분자특이로 라벨되고 가치 주장은 후자에서만 한다. **P3 선택적 발행** — 근거가 부족하면 기권한다.

입력 SMILES · 비임상 요약(NOEL·표적장기) · 적응증 · 상(phase) · 관할(식약처/FDA)



① MARKER 표기관 구조 → 리스크 플래그

RDKit FilterCatalog 8종 · Descriptors · 자체 SMARTS | 각 플래그에 σ(물 불일치)·AD(적용범위) 부착 | 항체·세포·핵산은 소분자 룰 비활성

▼ 리스크 플래그 + 신뢰도

② SCRIBE 기반관 리스크 × 맥락 → 조항 후보

조항에 템플릿 기저화물 p_base 부착 → 증분 Δ 산출 | 4-류플로만 발행: (근거 span, 유발 리스크, 봉인된 반증조건, 신뢰도) | LLM: 자유문 → 구조화 추출 · 조항 간 모순 탐지

▼ 조항 후보 + Δ

③ ACTUARY 계량관 용량 · 검증력 · 모집

NOAEL→HED→MRSD · 3+3 vs BLRM 몬테카를로 | 검증력 게이트: 탐지 불가 → 판정 보류 + 필요 N 제시 | 제외기준이 국내 등록가능 인구를 몇 % 깎는가

▼ 정량 근거

④ ADVERSARY 반증관 3중 반증 — 시스템의 심장

R1 근거 인용 원문 span 부재 → 기각 | R2 귀속 $\Delta^*(c) \leq 0 \rightarrow$ 구조 유래 아님, 기각 | R3 발행 모집 인구 감소 과다 → 기각

▼ 반증 통과분

⑤ LEDGER 원장관 선택적 발행 · 감사

$T(c) = \Delta^*(c) / (\alpha + \epsilon) \times AD \rightarrow T \geq \tau$ 발행 · 사람 검토 · $T < \tau_{low}$ 또는 $\Delta^* \leq 0$ 기권 | append-only 원장 · DAG 해시



산출 Go/No-Go 조항표(발행·가관-에스컬레이션) · COU 카드 · 감사 DAG · 재현성 봉인(seed-버전-해시)

되돌아가는 화살표 — 자기수정 루프

A1 R1 기각 → SCRIBE 재가관(최대 3회, 이후 기권) · A2 R2 기각 → MARKER 리스크 등급 하향 + 물 가중치 국소 재보정(Case Bank 영속화) · A3 R3 기각 → ACTUARY 회귀(제외기준 대신 용량 상한·모니터링 빈도로 대체 탐색) · A4 기권을 > 0.7 또는 동일 reason_code 반복 → 사람에게 계약 개정 요청(자동 완화 금지)

■ 결정론 도구가 판정 (숫자는 LLM 손에 없다) ■ LLM 관여 지점 (3곳뿐, 각각 ablation) ■ 반증 기각 · 기권

먹줄 아키텍처. 청색은 결정론 도구가 판정하는 지점, 회색은 LLM 관여 지점(3곳뿐), 붉은색은 반증 기각과 되돌아가는 화살표다. LLM이 숫자를 만들 경로가 구조적으로 없다.

■ 무엇이 새로운가 ① — Δ^* 구조 귀속 검정

"그 조항은 어차피 템플릿에 있는 것 아닌가"가 이 아이디어에 대한 가장 강한 반론이다. 먹줄은 그 반론을 기계적으로 자기 자신에게 적용한다.

$\Delta^*(c) = \Delta(c) - \max(0, \text{평균 } \Delta(\text{decoy}))$. MW·cLogP·TPSA·HBD·고리수는 매칭하고 지목한 구조 경보만 파괴한 대조 분자를 RDKit RWMol로 만들어, 거기서도 나오는 뭇을 빼낸다. 남은 것이 순수하게 구조에 귀속되는 증분이며 $\Delta^* \leq 0$ 이면 시스템이 스스로 기각한다. 시연 분자에서 QT 조항 원시 증분 +0.178 중 구조 귀속분은 +0.048(27%)뿐이었다. decoy는 정답이 아니라 음성

대조군이다. 정답은 실제 프로토콜 원문이다. 물성 기반 경보($cLogP \geq 3.7$)는 물성 그 자체라 절제할 수 없어 귀속 판정을 보류한다.

■ 무엇이 새로운가 ② — 기권을 산출물로 삼는 발행 규칙

신뢰도 $T(c) = \Delta^*(c) / (\sigma(c) + \epsilon) \times AD(m)$ 로 3분기한다. σ 는 룰 양상블 부트스트랩 불일치, AD는 학습 분포 근접도(ECFP4 최대 Tanimoto)다.

조건	판정	의미
$T(c) \geq \tau$	발행	근거 span·유발 리스크·봉인된 반증조건을 함께 발행
$\tau_{low} \leq T(c) < \tau$	사람 검토	안전성 조항·규제 상충·모달리티 범위 외는 무조건 여기로
$T(c) < \tau_{low}$ 또는 $\Delta^*(c) \leq 0$	기권	발행하지 않는다. 기권율을 시스템이 스스로 보고한다

에이전트는 자기 합격 기준을 낮출 수 없다. τ 완화와 kill criteria 변경은 사람 서명 없이 불가능하고 변경 차분이 원장에 남는다. 기권율이 0.7을 넘으면 자동 완화 대신 사람에게 계약 개정을 요청한다. 주지표는 재현율이 아니라 안전성 조항을 '불필요'로 오판한 비율(FOR_safety)이며, 2%를 넘으면 절감 주장을 철회한다.

선택적 예측·conformal prediction은 확립된 기법이며 우리 발명이 아니다. 우리의 기여는 그것을 규제 조항 발행 지점에 적용하고, Δ^* 귀속 검정·템플릿 증분 평가·조항 단위 COU 카드와 결합한 데 있다.

3 기술적 실현 가능성

1인 참가다. 그래서 범위를 좁히고, 이미 만든 것으로 증명한다.

■ 오프라인 우선 설계 — 이미 동작하는 부분

핵심 파이프라인은 외부 API·GPU·LLM 호출 없이 동작한다. 아래는 실제 실행 로그를 그대로 옮긴 것이다.

입력 CN1CCN(c2ccc(C(=O)Nc3ccc(Cl)cc3C(F)(F)F)cc2)CC1 MW 398 · cLogP 4.36 · 1상 · 진행성 고형암 구조경보 4건 적용범위 AD 0.31							
조항	분류	템플릿 기저	Δ 증분	Δ* 구조귀속	신뢰도 T	판정	사유
QT·심전도	분자특이	0.320	+0.1776	+0.0482	0.44	사람검토	trust_in_review_band
CYP·약물상호작용	분자특이	0.240	+0.0897	+0.0572	0.62	사람검토	trust_in_review_band
간기능	템플릿	0.655	-0.1656	-0.1656	-1.77	기권	no_structural_trigger
신기능	템플릿	0.437	-0.1242	-0.1242	-1.23	기권	no_structural_trigger
혈액학적	템플릿	0.549	-0.1991	-0.1991	-2.14	기권	no_structural_trigger

Δ* 가 실제로 걸려냈다. QT 조항의 원시 증분 +0.178 중 구조에 귀속되는 몫은 **+0.048(27%)** 뿐이었다. 나머지 73%는 물성 매칭 decoy 12개에서도 그대로 나왔다 — 즉 구조 때문이 아니다.

발행 0 · 사람검토 2 · 기권 3
기권을 60%

실행 추적 — 그대로 시연 화면이 된다

[0] **MARKER** 4건 검출: ['basic_amine', 'halogenated_aromatic', 'herg_pharmacophore', 'lipophilic'] · AD=0.31
[1] **SCRIBE** 5종 · 분자특이 2종 · Δ 범위 [-0.199, +0.178]
[2] **ACTUARY** NOAEL 25.0 mg/kg (rat) → HED 4.032 → SF10 → MRSD 0.4032 mg/kg = 24.19 mg/60kg
[3] **ACTUARY** N=60, 0.100→0.250 · power=0.58 · 부족 → 필요 N≈101
[4] **ADVERSARY** QT_ECG: Δ=+0.1776 · decoy 12개 평균 Δ=+0.1294(sd 0.0000) → Δ*=+0.0482 · 구조 귀속분 27%
[5] **ADVERSARY** CYP_DDI: Δ=+0.0897 · decoy 12개 평균 Δ=+0.0325(sd 0.0075) → Δ*=+0.0572 · 구조 귀속분 64%
[6] **LEDGER** 발행 0 · 사람검토 2 · 기권 3 (기권을 60%)
[7] **ACTUARY** 발행 조항 기준 등록가능 인구 0.0% 감소 · 통과

감사 DAG 해시 dbbe61e7d7d5d249190f23bf7a8d2a5... · RDKit 2026.03.4 · scikit-learn 1.9.0 · **3회 반복 실행 해시 일치**

실제 실행 결과. 5개 에이전트가 조항을 기안하고 Δ*로 스스로 기각하며 기권한다. 3회 반복 실행 시 감사 DAG 해시가 일치한다.

에이전트	도구 (전부 설치·실행 확인)	상태
MARKER	RDKit FilterCatalog 8종 · Descriptors · 자체 SMARTS 15종	동작
SCRIBE	조항 템플릿 YAML · 정규식 라벨러 · LLM(텍스트→구조 추출)	부분
ACTUARY	scipy · numpy · statsmodels (MRSD·검정력·몬테카를로)	설계
ADVERSARY	RDKit RWMol(decoy 생성) · scipy.stats(Fisher·부트스트랩)	동작
LEDGER	SQLite + SHA-256 append-only · networkx(감사 DAG) · LangGraph	설계
본선 추가	ClinicalTrials.gov API v2 · openFDA · Europe PMC · Boltz-2	본선

■ 본선 4주 계획과 축소 순서

주차	산출물	완료 판정
W1	조항 라벨러 v2 + 사람 검토 200건	Cohen's $\kappa \geq 0.6$ 보고
W2	Δ* 귀속 검정 + decoy 생성기 전면 가동	E2 결과표 확정
W3	LEDGER 원장·COU 카드·감사 DAG + HITL 인터럽트	3회 실행 해시 일치
W4	시연 UI + 사용자 스터디 3인 + 최종 보고서	검토 시간 실측치 대체

일정이 밀리면 이 순서로 버린다 — ① 본선 신규 도구(Boltz-2) ② 조항 유형 12종→6종 ③ 사용자 스터디 3인→1인 ④ 시연 UI 정교화. **절대 버리지 않는**

4가지는 B-TPL 템플릿 베이스라인 · Δ^* 귀속 검정 · 기권 기제 · 재현성 봉인이다. 이 넷이 빠지면 시스템의 주장이 성립하지 않는다.

4 에이전트 평가 적절성

한계를 먼저 쓴다. 조항 라벨은 정규식 v1이며 사람 검토로 κ 를 재기 전까지 근사다. 병용요법에서 대표 분자 1개 선택은 신호를 희석한다. 적응증 총화는 2분할로 거칠다. TrialBench는 2024-02-16 이전 등록 시험 기반이다. 데이터셋 라이선스가 저장소에 명시되지 않아 논문 data availability로 재확인 필요하다.

E1 SAFE-INC — 템플릿 대비 증분 실측

NCT ID 해시 기준 결정론적 분할(학습 27,593 / 평가 11,786). 커버리지 5%에서 상위 조항만 발행했을 때의 정밀도를 템플릿 베이스라인과 비교했다.

기전 확증 조항	기저율	템플릿 P@5%	먹줄 P@5%	$\Delta P@5\%$
QT·심전도	0.194	0.535	0.569	+0.034
CYP·약물상호작용	0.109	0.234	0.314	+0.080
간기능	0.360	0.727	0.716	-0.010
음식·자몽 제한	0.031	0.141	0.165	+0.024
위장관 궤양 병력	0.064	0.070	0.115	+0.046

확증된 기전을 가진 5개 조항. 평균 $\Delta P@5\%$ +0.035 · $\Delta AUPRC$ +0.026.

우리가 설명하지 못한 신호가 더 크다. 기전을 선언하지 않았거나 확증되지 않은 5개 조항(신기능·혈액·경련·위산·갑상선)의 증분은 $\Delta P@5\%$ +0.044로, 확증군(+0.035)보다 크다. 연속 물성만으로 얻은 신호이며 기전으로 설명하지 못한다. **헤드라인에 섞지 않고 분리해 보고하며, 이 설명 격차를 본선 연구과제로 명시한다.**

가장 중요한 음성 결과. 확증된 경보를 그대로 조항으로 발행하는 규칙 엔진(B-RULE)은 템플릿보다 **나빴다**($\Delta AUPRC$ -0.086). 경보를 조항으로 직역하면 해롭다. **선택적 발행과 기권은 취향이 아니라 데이터가 강제한 설계다.**

■ E3 NULL — 기권·오판·자기수정 실측

되돌아가는 화살표가 실제로 돈다 — 리도카인(NCT03562481) 실행 로그

ORCHESTRATOR 라운드 1 시작 하향된 경보 없음
SCRIBE 조항 후보 기간 5중 · 분자특이 1중 · Δ 범위 [-0.067, -0.005]
ADVERSARY R1 근거 반증 CYP_DDI: 근거 문서 ['ICH_M12'] 를 코퍼스에서 찾지 못함 → 격리
ADVERSARY R1 근거 반증 HEPATIC: 근거 문서 ['FDA_DILI'] 를 코퍼스에서 찾지 못함 → 격리
ADVERSARY R1 근거 반증 RENAL: 근거 문서 ['FDA_RENAL_IMP'] 를 코퍼스에서 찾지 못함 → 격리
ADVERSARY R1 근거 반증 HEMATO: 근거 문서 미특정 를 코퍼스에서 찾지 못함 → 격리
ADVERSARY R2 구조 귀속 검증 QT_ECG: Δ=-0.0054 · decoy 12개 평균 Δ=-0.0278(sd 0.0092) → Δ*=-0.0054 → 구조 유래 아님, 기각
MARKER A2 리스크 등급 하향 QT_ECG: ['R-basic_amine-00'] 를 트리거 자격에서 제외 (Case Bank 기록)
ORCHESTRATOR A4 계약 개정 요청 기권을 100% > 70% · 주 사유 'no_structural_trigger' → 사람에게 승격. 임계를 자동으로 낮추지 않는다
라운드 1에서 경보가 기각·하향되자 라운드 2에서 분자특이 조항이 1중→0중으로 줄고 수렴했다. 기권을 100%가 감지되자 임계를 낮추는 대신 사람에게 계약 개정을 요청했다.

주지표 FOR_safety

1.28%

목표 2% 이하 통과
[0.70%, 2.35%]

CYP-DDI 정밀도 lift

2.29x

[1.56, 3.22]
신뢰구간이 1을 넘지 않음

QT-심전도 lift

1.09x

[0.78, 1.47]
유의하지 않음 — 주장 안 함

음성 대조 발행률

0.0000

확증 경보 없는 3,274쌍
누출 0건

집계 지표의 함정을 우리가 먼저 밝힌다. 전체를 풀링한 '발행분 정밀도÷유병률'은 0.91배로 나와 시스템이 나쁜 것처럼 보인다. 이는 심슨의 역설이다 — 조항별 기저율이 3배 넘게 차이난데(간기능 0.385 vs CYP 0.101) 시스템은 기저율 높은 조항을 거의 발행하지 않기 때문이다. 그래서 조항별 lift와 신뢰구간을 주지표로 쓰고, 발행 가중 집계는 1.59배다.

되돌아가는 화살표가 실제로 돈 로그와 E3 지표. 주장 범위를 신뢰구간이 1을 넘지 않는 CYP-DDI로 좁히고, QT는 측정치만 보고한다.

■ 사전 선언 기전 게이트

사전 선언 18쌍 중 **확증 8 · 기각 10**(확증률 33.3%). 확증 5쌍은 1쪽 표에 있다. 기각 중 **방향이 반대로 유의한 것이 둘이다** — 티오펜→간기능 lift **0.57**(p=8.9e-28), 마이클 수용체→간기능 0.84(p=5.3e-15). **티오펜의 반응성 대사체→간독성은 의약화학 교과서적 경보인데 실제 프로토콜 4만 건에서는 반대로 나왔다.** 검증 없이 구조 경보를 조항으로 번역하면 안 된다는 우리 설계의 직접 근거다.

■ 왜 이 설계인가

구조 플래그 15종 × 조항 8종을 전수 검정하면 다중검정 보정 후에도 기전으로 설명되지 않는 유의한 연관이 쏟아진다. 실제로 PAINS와 방향족 아민이 **피임 조항**까지 유의하게 예측했다. 이는 화학이 아니라 **적응증·약물계열 교락**이다. 통계적 유의성만으로는 "유의한 것만 골라 썼다"는 비판을 방어할 수 없다.

그래서 **결과를 보기 전에** 기전 가설 18쌍을 선언하고 세 갈래로 분류한다. **confirmatory**(선언+통계+층화 통과)만 가치 주장에 쓰고, **exploratory**(선언 안 했으나 유의)는 보고만 하며, **refuted**(선언했으나 실패)는 실패로 적는다. PAINS는 어세이 간섭 필터이므로 임상 조항의 기전 근거로 쓰지 않는다고 못박았다.

지표	정의	목표
$\Delta P@C$	커버리지 C에서 정밀도 - 템플릿 베이스라인 정밀도	헤드라인
FOR_safety	실제 존재하는 안전성 조항을 '불필요'로 판정한 비율	$\leq 2\%$
기권율 / AURC	발행하지 않은 비율 / risk-coverage 곡선 하 면적	함께 보고
확증률	사전 선언 쌍 중 확증된 비율	실측 33.3%
DPR	동일 시드 3회 실행의 감사 DAG 해시 일치율	100%

모든 비율에 Wilson 95% 신뢰구간을 병기한다. FOR_safety가 2%를 넘으면 절감 주장 자체를 철회한다.

5 AI 활용 투명성 및 연구 윤리

■ AI를 연구동료로 어떻게 썼는가

단계	AI에게 시킨 것	사람이 한 것	기각한 AI 산출물
주제 선정	컨셉 4종 생성 + 3인 심사 패널 비교채점	최종 선택·이식 결정	융합 분야안(서사 산만)
근거 조사	선행연구·데이터셋·규제 문서 검색	URL 접속으로 실재 확인	출처 불명 수치 전량
실측·구현	분석·에이전트 코드 작성	재실행해 수치 재현 검증	'라이선스 명기' 허위 서술
집필	초안 생성	문장·수치 전수 대조	과장된 절감 주장

AI가 생성한 서술 중 저장소에 LICENSE 파일이 있다는 진술이 사실이 아님을 확인해 삭제했고, 실측 수치는 스크립트를 직접 재실행해 전부 재현했다. 대화 기록·프롬프트·모델명·기각 사유는 저장소에 남긴다.

■ 윤리를 문단이 아니라 자료형으로

모든 조항은 provenance를 자료형으로 강제한다. `kind`가 `computed`가 아닌데 `url`이나 `span\_id`가 없으면 **시스템이 자동으로 unverified로 격리하고 판정 가중치를 0으로 만든다**. 근거 없는 인용이 결론에 도달할 경로 자체를 없앤다. 격리율을 지표로 보고한다.

■ 먹줄이 하지 않는 것

- 분자를 새로 생성하지 않는다. 입력받은 구조를 판정만 한다.
- 합성 경로를 제안하지 않는다. 유해 물질 합성 경로 오남용 경로가 원천적으로 없다.
- 독성을 예측했다고 말하지 않는다. 프로토콜 조항의 필요성을 추정할 뿐이다.
- 규제 판단을 대체하지 않는다. 산출물은 RA 담당자의 검토 대상 목록이다.
- 자기 합격 기준을 낮출 수 없다. kill criteria 완화는 사람 서명 없이 불가능하다.

유전독성 불순물 경보와 위험 시약 관련 hard veto는 **사람도 우회할 수 없다**. 안전성 조항의 신뢰도 미달, 규제 상충, 모달리티 범위 외는 무조건 사람에게 승격된다.

6 본선 시연 시나리오

심사위원이 보아야 할 것은 결과가 아니라 **판단이 뒤집히는 순간**이다. 3막으로 구성한다.

막	무엇을 보여주는가	심사위원이 확인하는 것
1막 연역	실제 공개 임상시험의 SMILES를 입력한다. 좌측에 구조 경보, 우측에 조항 후보가 템플릿 기저 확률과 함께 쌓인다.	숫자가 결정론 도구에서 나온다는 것. LLM이 만진 곳은 회색으로 표시된다.
2막 반증	ADVERSARY가 돌면서 조항이 실시간으로 지워진다 . $\Delta^* \leq 0$, 근거 span 부재, 모집 인구 과다 감소로 기각되는 조항을 각각 보여준다.	시스템이 자기 산출물을 죽인다는 것 . 기권이 산출물이라는 것.
3막 대조	그 시험의 실제 선정·제외기준 원문을 나란히 띄운다. 맞힌 조항·놓친 조항·헛발질한 조항을 색으로 구분하고 틀린 것을 화면에 남긴다 .	정답 대비 성능. 실패를 감추지 않는다는 것.

사고 과정의 시각화는 감사 DAG를 그대로 렌더링한다. 노드는 도구 호출, 엣지는 데이터 의존, 색은 결정론/LLM, 붉은 엣지는 되돌아간 경로다. 같은 시드로 다시 돌리면 **같은 DAG 해시가 나오는 것을 현장에서 보여준다**. 재현성을 말이 아니라 해시로 증명한다.

마지막 30초에는 **실패 카탈로그**를 띄운다. 티오펜 가설이 반대로 나온 사례를 포함해, 우리가 틀렸던 것을 우리가 먼저 보여준다.

7 API 및 GPU 관련 예상 소요 규모

결정론 코어가 무거운 일을 하므로 LLM 호출은 얇다. 아래는 조항당 실측 기반 추정이며 산출식을 그대로 공개한다.

용도	단위 규모	4주 누적	근거
텍스트→구조화 추출	프로토콜당 입력 8K·출력 2K 토큰	약 6M 토큰	시험 500건 × 라운드 3
조항 간 모순 탐지	조항 12종 × 입력 3K 토큰	약 5M 토큰	조항 발행 시 1회
상충 카드 서술	발행 조항당 출력 0.5K 토큰	약 1M 토큰	발행분에 한정
평가 하네스 재실행	전체 3회 반복(재현성 검증)	약 4M 토큰	DPR 측정
합계	—	약 16M 토큰	여유율 30% 포함

■ GPU

예선 파이프라인은 **GPU가 필요 없다**. RDKit·scipy 기반 결정론 연산이며 39,379건 전수 분석이 CPU 4코어에서 수 분 내에 끝난다. 본선에서 GPU를

쓰는 지점은 하나다 — Boltz-2 기반 off-target(hERG) 구조 예측으로, 후보 20~30건에 대해 A100 기준 누적 약 20~30 GPU·시간을 추정한다. 이 항목은 축소 순서 1순위이며, 빠져도 시스템의 핵심 주장은 성립한다.

리소스 효율이 곧 설계 원칙이다. 숫자를 LLM에게 시키지 않아 토큰이 적게 들고, 기권 기재 덕에 확신 없는 조항에 추론을 낭비하지 않는다. 조항당 토큰과 wall-clock을 실측해 보고한다.

8 에이전트 도입에 따른 파급효과

프로토콜 수정 1건의 직접비는 2상 US\$141,000, 3상 US\$535,000이다. 그러나 이 금액을 우리 절감액으로 청구하지 않는다. 수정 유발 요인에는 모집 난항·신규 안전성 정보·규제기관 요청이 포함되며 구조에서 연역되지 않는다. 하루 원가의 크기를 보여주는 앵커로만 쓴다.

효과	근거 유형	내용
검토 대상 축소	실측	기권을 91%. 대부분이 템플릿임을 데이터로 분리해 분자 특이 조항에만 집중하게 한다
누락 조항 조기 발견	실측	CYP·DDI 발행분 정밀도 lift 2.29배 [1.56,3.22]. QT는 신뢰구간이 1을 포함해 주장하지 않음
검토 물량 절감	실측	CYP·DDI에서 같은 수의 실제 조항을 찾기까지 검토량 25% 절감 (커버리지 5% 기준 정밀도 0.234→0.314, 0.234/0.314=74.6%). 측정된 정밀도에서 직접 유도한 값이며 추정이 아니다
검토 시간	추정	조항 200~400개 × 3분 = 10~20시간/라운드(산출식 공개). 본선 사용자 스터디로 실측 대체. IND 보완은 사유별 공개 통계가 없어 발생률을 수치화하지 않는다

도입 경로 — 1단계 기존 프로토콜 검수(사후 진단) → 2단계 초안 작성 시 조항 제안 → 3단계 제출 패키지에 COU 카드·감사 DAG 첨부. 1단계는 폐쇄망에서 즉시 가능하며 국내 중소 바이오텍의 실제 진입점이다.

산업 경쟁력 기여는 방법론이다. 비결정적 멀티에이전트를 규제 환경에서 쓰려면 COU 정의와 재현성 입증에 필요한데 현재 그 방법이 없다. 먹줄의 조항 단위 COU 카드와 감사 DAG 해시는 다른 규제과학 에이전트에 그대로 이식 가능한 형식이다.

참고문헌 (URL 접속으로 실재 확인, 확인일 2026-07-26)

[1] Getz et al. The Impact of Protocol Amendments on Clinical Trial Performance and Cost. Ther Innov Regul Sci. doi 10.1177/2168479016632271 · [2] Chen et al. TrialBench: Multi-Modal AI-Ready Datasets for Clinical Trial Prediction. Scientific Data 2025. s41597-025-05680-8 · [3] Mitchener et al. BixBench. arXiv:2503.00096 · [4] Das et al. AMEND++. arXiv:2601.06300 · [5] FDA. Considerations for the Use of AI to Support Regulatory Decision-Making for Drug and Biological Products. Draft Guidance 2025-01 · [6] 식품의약품안전처. 의약품 개발 시 AI 활용 안내서 / 2026년 주요업무 추진계획 · [7] 한국보건산업진흥원. 국내 신약개발 임상단계별 성공률 분석 · [8] Schrag et al. CiteME. arXiv:2407.12861 · [9] Schmidgall et al. AgentClinic. arXiv:2405.07960