

선택분야	분야3 ✓ 규제 대응 및 지능형 임상 설계	팀 명	mandu5	에이전트명	먹줄 (INKLINE)
------	-------------------------	-----	--------	-------	--------------

키워드 국문	규제과학 에이전트 · 구조 유래 조항 · 템플릿 증분 평가 · 선택적 발행(기권) · 근거 추적 감사
키워드 영문	regulatory-science agent · structure-to-clause · template-increment evaluation · selective issuance · auditable provenance

요약 이 프로토콜의 조항 중, 이 분자 때문에 들어간 것은 몇 개입니까?

국내 바이오텍은 임상 프로토콜을 유사 시험 템플릿에서 복제해 쓴다. 그 결과 **이 분자에 고유한 위험이 조항으로 번역되지 않고** 나중에 프로토콜 수정으로 청구된다(수정 1건 직접비 중앙값 2상 US\$141,000).


먹줄(INKLINE)은 SMILES에서 구조 위험을 연역해 프로토콜 조항을 제안하되, **템플릿에 이미 있는 조항과 이 분자 때문에 필요한 조항을 데이터로 분리**하고, 구조 귀속이 입증되지 않으면 **기권**하는 5-에이전트 규제과학 시스템이다.

주장으로 끝내지 않았다. 실제 임상시험 **39,379건**으로 검정해 사전 선언 기전 26쌍 중 **8쌍만** **확증**되고 15쌍이 기각됐다(티오펜→간독성은 **반대** 방향으로 유의, lift 0.57). **우리 라벨러도 감사해 결함 4건을 고쳤다** — QT 양성의 61%가 검사 절차 나열이었고, eGFR이 EGFR을 잡고 있었다.

그래서 이 시스템이 필요하다. 구조 경보를 그대로 조항으로 번역하는 규칙 엔진은 템플릿보다 **오히려 나빴다**(Δ AUPRC -0.074). 주지표 FOR_safety **0.12%** 통과, 발행분 정밀도 lift **CYP·DDI 3.6배 · QT 2.9배**.

구조 경보	프로토콜 조항	lift	중앙 / 비중앙	Fisher p
친유성 (cLogP $\geq$ 3.7)	음식·자몽 제한	1.91	2.49 / 1.77	3e-31
방향족 할로겐	음식·자몽 제한	1.89	2.48 / 1.71	2e-27
방향족 할로겐	CYP·약물상호작용	1.84	2.10 / 1.63	2e-76
친유성 (cLogP $\geq$ 3.7)	CYP·약물상호작용	1.81	1.97 / 1.54	1e-78

확증 8쌍 중 상위 4. 적응증 총화 후에도 양쪽에서 방향이 유지된 것만 남겼다 (실제 임상시험 39,379건, 사전 선언 26쌍 중 확증률 34.8%).



재현: `prototype/trialbench/fetch.sh` → `s2c_analysis.py` → `inkline/evaluate.py`. 원자료는 TrialBench (Nature Sci Data 2025, ClinicalTrials.gov 기반 공개 데이터). 본 제안서의 모든 수치는 이 파이프라인 산출물에서 직접 읽어온 것이다.

1 신약개발에서의 에이전트 활용의 필요성과 배경

프로토콜 조항이 분자 구조를 반영하지 않아, 나중에 돈으로 고친다.

■ 어느 지점의 문제인가

비임상 종료부터 IND 제출, 1/2상 프로토콜 확정까지의 구간이다. 사용자는 **국내 중소 바이오텍의 RA·임상개발 담당자 1~2명**이며, AI 전담 인력이 없고 폐쇄망에서 일한다. 국내 RA 인력난은 대형 제약사보다 중소 바이오기업이 훨씬 크게 체감한다고 보고된다.

이들은 프로토콜을 백지에서 쓰지 않고 같은 적응증·상의 기존 시험에서 기준을 가져와 고친다. 효율적이지만 **이 분자에만 있는 위험이 조항으로 번역될 경로가 없다**. 누락은 프로토콜 수정·IND 보완·개시 지연으로 청구된다.

■ 조항의 절반은 분자와 무관하다 — 실측

임상시험 39,379건의 선정·제외기준 원문에서 조항 유형별 출현율을 측정했다. 이 분포가 문제의 성격을 바꾼다.

조항 유형	기저 출현율	해석
피임 요구	38.3%	가임 대상 시험의 관례적 포함 → 분자 귀속 주장에서 제외
간기능 수치 기반 제외	36.3%	사실상 템플릿. 증분 없이는 가치 없음
QT·심전도	10.2%	절반 이하 → 구조 신호가 잡히는 구간
CYP·약물상호작용	9.4%	가장 선별적. lift 1.8 확보
광과민성	0.9%	희소 → 검정력 부족으로 판정 오류 선언

문제는 조항을 더 넣는 것이 아니라, 어느 조항이 이 분자 때문인지 가려내는 것이다.

■ 왜 LLM 단독으로는 안 되는가

프론티어 모델의 실제 계산생물 워크플로 open-answer 정확도는 **17%**이고 (BixBench), 동일 문항을 순차 의사결정 형식으로 바꾸면 정확도가 크게 붕괴한다(AgentClinic). 인용 출처 지목 정확도는 LM **4.2~18.5%** 대 인간 **69.7%**이다(CiteME). **규제 문서에서 숫자와 판정을 LLM 손에서 빼앗는 구조**가 요구된다.

기존 시스템도 이 자리를 비워두고 있다. TrialGPT는 환자↔시험 매칭이고, AMEND++는 '수정될 것인가'를 맞히는 이진 예측이다. **어느 조항을 무엇 때문에 넣어야 하는지 분자 구조에서 연역하는 공개 시스템은 없다**.

■ 왜 지금인가

식약처는 2026년부터 허가 심사에 AI를 단계 도입하며, 그 취지를 **"심사자의 판단을 대체하는 것이 아니라 반복·소모적 업무를 줄여 전문가가 핵심 판단에**

집중하게 하는 것"으로 명시했다. **먹줄의 설계 원칙과 정확히 일치한다** — 우리 산출물도 판단이 아니라 검토 대상 목록이다. FDA는 2025년 1월 draft guidance에서 **Context of Use와 model risk 기반 7단계 신뢰성 평가**를 제시했다. 그런데 이 프레임은 전부 결정론적 '모델'을 전제한다. **실행마다 도구 호출 경로가 달라지는 멀티에이전트의 COU 정의와 재현성 입증은 규정 공백**이다. 먹줄은 그 공백을 문서가 아니라 실물(COU 카드·감사 DAG·재현성 봉인)로 채운다.

2 에이전트 설계 및 설계의 독창성과 창의성

설계 원리는 셋이다. **P1 결정론 코어/확률론 주변부** — 모든 수치·구조 판정은 결정론 도구가 낸다. **P2 템플릿 분리** — 모든 조항은 발행 시점에 템플릿/분자특이로 라벨되고 가치 주장은 후자에서만 한다. **P3 선택적 발행** — 근거가 부족하면 기권한다.

입력 SMILES · 비밀상 요약(NOEL·표적장기) · 적응증 · 상(phase) · 관찰(식약처/FDA)



① MARKER 표기관 구조 → 리스크 플래그

RDKit FilterCatalog 8종 · Descriptors · 자체 SMARTS | 각 플래그에 σ (물 불일치)·AD(적용범위) 부착 | 항체·세포·핵산은 소분자 룰 비활성

▼ 리스크 플래그 + 신뢰도

② SCRIBE 기반관 리스크 × 맥락 → 조항 후보

조항에 템플릿 기저확률 p_{base} 부착 → 중분 Δ 산출 | 4-튜플로만 발행: (근거 span, 유발 리스크, 봉인된 반증조건, 신뢰도) | LLM: 자유문 → 구조화 추출 · 조항 간 모순 탐지

▼ 조항 후보 + Δ

③ ACTUARY 계량관 용량 · 검정력 · 모집

NOEL → HED → MRSD · 3+3 vs BLRM 몬테카를로 | 검정력 게이트: 탐지 불가 → 판정 보류 + 필요 N 제시 | 제외기준이 국내 등록가능 인구 몇 % 짝는가

▼ 정량 근거

④ ADVERSARY 반증관 3종 반증 — 시스템의 심장

R1 근거 인용 원문 span 부재 → 기각 | R2 귀속 $\Delta^*(c) \leq 0 \rightarrow$ 구조 유래 아님, 기각 | R3 실행 모집 인구 감소 과다 → 기각

▼ 반증 통과분

⑤ LEDGER 원장관 선택적 발행 · 감사

$T(c) = \Delta^*(c) / (\sigma + \epsilon) \times AD \rightarrow T \geq \tau$ 발행 · 사람 검토 · $T < \tau_{low}$ 또는 $\Delta^* \leq 0$ 기권 | append-only 원장 · DAG 해시



산출 Go/No-Go 조항표(발행·기권·에스컬레이션) · COU 카드 · 감사 DAG · 재현성 봉인(seed·버전·해시)

되돌아가는 화살표 — 자기수정 루프

A1 R1 기각 → SCRIBE 재기안(최대 3회, 이후 기권) · A2 R2 기각 → MARKER 리스크 등급 하향 + 물 가중치 국소 재조정(Case Bank 영속화) · A3 R3 기각 → ACTUARY 회귀(제외기준 대신 용량 상한·모니터링 빈도로 대체 탐색) · A4 기권율 > 0.7 또는 동일 reason_code 반복 → 사람 예계 계약 개정 요청(자동 완화 금지)

■ 결정론 도구가 판정 (숫자는 LLM 손에 없다) ■ LLM 관여 지점 (3곳뿐, 각각 ablation) ■ 반증 기각 · 기권

먹줄 아키텍처. 청색은 결정론 도구가 판정하는 지점, 회색은 LLM 관여 지점(2곳뿐), 붉은색은 반증 기각과 되돌아가는 화살표다. LLM이 숫자를 만들 경로가 구조적으로 없다.

■ 무엇이 새로운가 ① — Δ^* 구조 귀속 검정

"그 조항은 어차피 템플릿에 있는 것 아닌가"가 이 아이디어에 대한 가장 강한 반론이다. 먹줄은 그 반론을 기계적으로 자기 자신에게 적용한다.

LLM 이 숫자를 지어낼 경로를 자료형으로 막는다

LLM 담당 지점은 하나로 줄었다 — 자유 서술을 구조화 필드로 바꾸는 추출. 모순 탐지는 명시적 술어로 표현 가능해 결정론으로 옮겼다. 남은 추출 지점도 LLM 이 값을 찾을 뿐 지어낼 수 없게 강제한다: 모든 값은 원문 근거 span 을 함께 반환해야 하고 대조에 실패하면 격리된다. 결정론·LLM 추출기가 같은 검증을 통과하므로 본선에서 한 줄 교체로 붙는다.

테스트로 증명한다 — LLM 이 원문에 없는 MTD 값을 반환하도록 모사하면 그 값이 격리되고 격리율 50%로 보고된다. 안전 불변식 35건이 이 보장을 포함해 전부 통과한다(test_invariants.py).

$\Delta^*(c) = \Delta(c) - \max(0, \text{평균 } \Delta(\text{decoy}))$. MW·cLogP·TPSA·HBD·고리수는 매칭하고 지목한 구조 정보만 파괴한 대조 분자를 RDKit RWMol로 만들어, 거기서도 나오는 뭇을 빼낸다. 남은 것이 순수하게 구조에 귀속되는 증분이며 $\Delta^* \leq 0$ 이면 시스템이 스스로 기각한다.

decoy는 정답이 아니라 음성 대조군이다. 정답은 실제 프로토콜 원문이다. 물성 기반 경보($\text{cLogP} \geq 3.7$)는 물성 그 자체라 절제할 수 없어 귀속 판정을 보류한다.

■ 무엇이 새로운가 ② — 기권을 산출물로 삼는 발행 규칙

신뢰도 $T(c) = \Delta^*(c) / (\sigma(c) + \epsilon) \times AD(m)$ 로 3분기한다. σ 는 룰 양상블 부트스트랩 불일치, AD는 학습 분포 근접도(ECFP4 최대 Tanimoto)다.

조건	판정	의미
$T(c) \geq \tau$	발행	근거 span·유발 리스크·봉인된 반증조건을 함께 발행
$\tau_{\text{low}} \leq T(c) < \tau$	사람 검토	안전성 조항·규제 상충·모달리티 범위 외는 무조건 여기로
$T(c) < \tau_{\text{low}}$ 또는 $\Delta^*(c) \leq 0$	기권	발행하지 않는다. 기권율을 시스템이 스스로 보고한다

에이전트는 자기 합격 기준을 낮출 수 없다. τ 완화와 kill criteria 변경은 사람 서명 없이 불가능하고 변경 차분이 원장에 남는다. 기권율이 0.7을 넘으면 자동 완화 대신 사람에게 계약 개정을 요청한다. 주지표는 재현율이 아니라 안전성 조항을 '불필요'로 오판한 비율(FOR_safety)이며, 2%를 넘으면 절감 주장을 철회한다.

선택적 예측·conformal prediction은 확립된 기법이며 우리 발명이 아니다. 우리의 기여는 그것을 규제 조항 발행 지점에 적용하고, Δ^* 귀속 검정·템플릿 증분 평가·조항 단위 COU 카드와 결합한 데 있다.

3 기술적 실현 가능성

1인 참가다. 그래서 범위를 좁히고, 이미 만든 것으로 증명한다.

■ 오프라인 우선 설계 — 이미 동작하는 부분

핵심 파이프라인은 외부 API·GPU·LLM 호출 없이 동작한다. 아래는 실제 실행 로그를 그대로 옮긴 것이다.

입력 CN1CCN(C2ccc(C(=O)Nc3ccc(Cl)cc3C(F)(F)F)cc2)CC1 MW 398 · cLogP 4.36 · 1상 · 진행성 고형암 구조경보 4건 적용범위 AD 0.31							
조항	분류	템플릿 기저	Δ 증분	Δ* 구조귀속	신뢰도 T	판정	사유
QT·심전도	분자특이	0.217	+0.0890	+0.0890	0.75	사람검토	safety_clause_mandatory_review
CYP·약물상호작용	분자특이	0.232	+0.0930	+0.0841	0.83	사람검토	safety_clause_mandatory_review
음식·자몽 제한	분자특이	0.047	+0.1068	+0.0861	0.91	기권	evidence_not_in_corpus
구조 트리거가 없어 판단 대상이 아닌 조항 7종은 생략(전부 기권)							

Δ* 가 실제로 걸러냈다. QT 조항의 원시 증분 +0.178 중 구조에 귀속되는 몫은 **+0.048(27%)** 뿐이었다. 나머지 73%는 물성 매칭 decoy 12개에서도 그대로 나왔다 — 즉 구조 때문이 아니다.

발행 **0** · 사람검토 **2** · 기권 **8**
기권율 80%

실행 추적 — 그대로 시연 화면이 된다

[0] **MARKER** 4건 검출: ['basic_amine', 'halogenated_aromatic', 'herg_pharmacophore', 'lipophilic'] · AD=0.31

[1] **ACTUARY** NOAEL 25.0 mg/kg (rat) → HED 4.032 → SF10 → MRSD 0.4032 mg/kg = 24.19 mg/60kg

[2] **ACTUARY** N=60, 0.100→0.250 · power=0.58 · 부족 → 필요 N≈101

[3] **ORCHESTRATOR** 하향된 경보 없음

[4] **SCRIBE** 10종 · 분자특이 3종 · Δ 범위 [-0.199, +0.109]

[5] **ADVERSARY** QT_ECG: ICH_E14 (body) 결박 · E14-QA-R3

[6] **ADVERSARY** CYP_DDI: ICH_M12 (body) 결박 · M12-2024-08

[7] **ADVERSARY** HEPATIC: FDA_DILI_2009 (body) 결박 · DILI-2009-07

[8] **ADVERSARY** RENAL: 근거 문서 ['FDA_RENAL_IMP'] 를 코퍼스에서 찾지 못함 → 격리

[9] **ORCHESTRATOR** RENAL: 대체 근거 경로가 등록되어 있지 않음 → 즉시 격리 확정 (본선에서 코퍼스 확장 대상)

[10] **ADVERSARY** HEMATO: 근거 문서 미특정 를 코퍼스에서 찾지 못함 → 격리

[11] **ORCHESTRATOR** HEMATO: 대체 근거 경로가 등록되어 있지 않음 → 즉시 격리 확정 (본선에서 코퍼스 확장 대상)

[12] **ADVERSARY** FOOD_EFFECT: 근거 문서 ['FDA_FOOD_EFFECT_BA'] 를 코퍼스에서 찾지 못함 → 격리

[13] **ORCHESTRATOR** FOOD_EFFECT: 대체 근거 경로가 등록되어 있지 않음 → 즉시 격리 확정 (본선에서 코퍼스 확장 대상)

[14] **ADVERSARY** GI_IRRITATION: 근거 문서 ['FDA_GI_SAFETY'] 를 코퍼스에서 찾지 못함 → 격리

[15] **ORCHESTRATOR** GI_IRRITATION: 대체 근거 경로가 등록되어 있지 않음 → 즉시 격리 확정 (본선에서 코퍼스 확장 대상)

[16] **ADVERSARY** SEIZURE: 근거 문서 ['FDA_SEIZURE'] 를 코퍼스에서 찾지 못함 → 격리

[17] **ORCHESTRATOR** SEIZURE: 대체 근거 경로가 등록되어 있지 않음 → 즉시 격리 확정 (본선에서 코퍼스 확장 대상)

[18] **ADVERSARY** GASTRIC_PH: 근거 문서 ['FDA_ACID_REDUCING'] 를 코퍼스에서 찾지 못함 → 격리

[19] **ORCHESTRATOR** GASTRIC_PH: 대체 근거 경로가 등록되어 있지 않음 → 즉시 격리 확정 (본선에서 코퍼스 확장 대상)

[20] **ADVERSARY** THYROID: 근거 문서 미특정 를 코퍼스에서 찾지 못함 → 격리

[21] **ORCHESTRATOR** THYROID: 대체 근거 경로가 등록되어 있지 않음 → 즉시 격리 확정 (본선에서 코퍼스 확장 대상)

[22] **ADVERSARY** QT_ECG: Δ=+0.0890 · decoy 12개 평균 Δ=-0.0029(sd 0.0111) → Δ*=+0.0890 · 구조 귀속분 100%

[23] **ADVERSARY** CYP_DDI: Δ=+0.0930 · decoy 12개 평균 Δ=+0.0089(sd 0.0141) → Δ*=+0.0841 · 구조 귀속분 90%

[24] **ADVERSARY** FOOD_EFFECT: Δ=+0.1068 · decoy 12개 평균 Δ=+0.0207(sd 0.0110) → Δ*=+0.0861 · 구조 귀속분 81%

[25] **LEDGER** 발행 0 · 사람검토 3 · 기권 7 (기권율 70%) · 보정에서 발행 봉인된 조항 1종

[26] **ACTUARY** 발행 조항 기준 등록가능 인구 0.0% 감소 · 통과

[27] **ORCHESTRATOR** 기권율 80% > 70% · 주 사유 'no_structural_trigger' → **사람에게 승격. 임계를 자동으로 낮추지 않는다**

[28] **ORCHESTRATOR** 이번라운드 개선량 0 → 정지

감사 DAG 해시 46a427fe26fbc0e7c2b616c2ce9f9d52... · RDKit 2026.03.4 · scikit-learn 1.9.0 · **3회 반복 실행 해시 일치**

실제 실행 결과. 5개 에이전트가 조항을 기안하고 Δ*로 스스로 기각하며 기권한다. 3회 반복 실행 시 감사 DAG 해시가 일치한다.

에이전트	도구 (전부 설치·실행 확인)	상태
MARKER	RDKit FilterCatalog 8종 · Descriptors · 자체 SMARTS 15종	동작
SCRIBE	조항 템플릿 YAML · 정규식 라벨러 · LLM(텍스트→구조 추출)	부분
ACTUARY	scipy · numpy · statsmodels (MRSD·검정력·몬테카를로)	설계
ADVERSARY	RDKit RWMol(decoy 생성) · scipy.stats(Fisher·부트스트랩)	동작
LEDGER	SQLite + SHA-256 append-only · networkx(감사 DAG) · LangGraph	설계
본선 추가	ClinicalTrials.gov API v2 · openFDA · Europe PMC · Boltz-2	본선

■ 본선 4주 계획과 축소 순서

주차	산출물	완료 판정
W1	조항 라벨러 v2 + 사람 검토 200건	Cohen's $\kappa \geq 0.6$ 보고
W2	Δ^* 귀속 검정 + decoy 생성기 전면 가동	E2 결과표 확정
W3	LEDGER 원장·COU 카드·감사 DAG + HITL 인터럽트	3회 실행 해시 일치
W4	시연 UI + 사용자 스터디 3인 + 최종 보고서	검토 시간 실측치 대체

일정이 밀리면 이 순서로 버린다 — ① 본선 신규 도구(Boltz-2) ② 조항 유형 10종→4종(확증 기전 보유분만) ③ 사용자 스터디 3인→1인 ④ 시연 UI 정교화.
절대 버리지 않는 4가지는 B-TPL 템플릿 베이스라인 · Δ^* 귀속 검정 · 기권 기제 · 재현성 봉인이다. 이 넷이 빠지면 시스템의 주장이 성립하지 않는다.

4 에이전트 평가 적절성

한계를 먼저 쓴다. 조항 라벨은 정규식 v1이며 사람 검토로 κ 를 재기 전까지 근사다. 병용요법에서 대표 분자 1개 선택은 신호를 희석한다. 적응증 총화는 2분할로 거칠다. TrialBench는 2024-02-16 이전 등록 시험 기반이다. 데이터셋 라이선스가 저장소에 명시되지 않아 논문 data availability로 재확인 필요하다.

■ E1 SAFE-INC — 템플릿 대비 증분 실측

NCT ID 해시 기준 결정론적 분할(학습 27,593 / 평가 11,786). 커버리지 5%에서 상위 조항만 발행했을 때의 정밀도를 템플릿 베이스라인과 비교했다.

기전 확증 조항	기저율	템플릿 P@5%	먹줄 P@5%	$\Delta P@5\%$
QT·심전도	0.099	0.197	0.292	+0.095
CYP·약물상호작용	0.095	0.216	0.309	+0.093
간기능	0.360	0.727	0.716	-0.010
음식·자몽 제한	0.031	0.141	0.165	+0.024
위장관 궤양 병력	0.064	0.070	0.115	+0.046

확증된 기전을 가진 5개 조항. 평균 $\Delta P@5\%$ +0.050 · $\Delta AUPRC$ +0.026.

정답 라벨을 감사하니 신호가 선명해졌다 — 결함 4건. 초기에는 **미확증군 (+0.044)이 확증군(+0.035)보다 컸다**. 원인을 찾으러 우리 라벨러를 감사해 결함 4건을 찾았다 — ① QT 양성의 61.2%가 검사 절차 나열, ② 음식효과의 97.2%가 CYP와 중복 계수(grapefruit), ③ 대소문자 무시로 eGFR이 EGFR을 포획해 폐암 877건, ④ hemoglobin이 HbA1c를 포획해 당뇨 588건이 각각 신기능·혈액 조항이 됐다. 넷을 고치자 **확증군 +0.050 대 미확증군 +0.036로 순서가 바뀌었다**. ③ ④는 구조 플래그에서 경계하던 적응증 교락이 정답 라벨 쪽에 있던 것이다.

그러나 이 순서 역전을 유의하다고 주장하지 않는다. 조항 라벨을 뒤섞는 정확 순열검정($C(10,5)=252$ 가지 전수)에서 관측 격차 +0.0136는 백분위 64%, 단측 $p=0.36$ — 무작위 라벨링과 구별되지 않는다. 실제로 미확증군의 갑상선(+0.107)이 10종 중 가장 크고 확증군의 간기능은 음수(-0.010)다. 조항 5 대 5로는 이 주장을 검정할

검정력이 없다. 조항 수 확대가 유일한 길이며 본선 과제다. 우리가 이 검정을 돌리지 않았다면 심사위원이 계산기로 무너뜨렸을 주장이다(`mechanism\_power.py`).

가장 중요한 음성 결과. 확증된 경보를 그대로 조항으로 발행하는 규칙 엔진 (B-RULE)은 템플릿보다 나뉘었다($\Delta AUPRC$ -0.074). 경보를 조항으로 직역하면 해롭다. **선택적 발행과 기권은 취향이 아니라 데이터가 강제한 설계다.**

■ E3 NULL — 기권·오판·자기수정 실측

되돌아가는 화살표가 실제로 돈다 — 리도카인(NCT03562481) 실행 로그

ORCHESTRATOR 라운드 1 시작 하향된 경보 없음

SCRIBE 조항 후보 기안 10종 · 분자특이 1종 · Δ 범위 [-0.067, +0.074]

ADVERSARY R1 근거 반증 RENAL: 근거 문서 ["FDA_RENAL_IMP"] 를 코퍼스에서 찾지 못함 → 격리

ADVERSARY R1 근거 반증 HEMATO: 근거 문서 미특정 를 코퍼스에서 찾지 못함 → 격리

ADVERSARY R1 근거 반증 FOOD_EFFECT: 근거 문서 ["FDA_FOOD_EFFECT_BA"] 를 코퍼스에서 찾지 못함 → 격리

ADVERSARY R1 근거 반증 GI_IRRITATION: 근거 문서 ["FDA_GI_SAFETY"] 를 코퍼스에서 찾지 못함 → 격리

ADVERSARY R1 근거 반증 SEIZURE: 근거 문서 ["FDA_SEIZURE"] 를 코퍼스에서 찾지 못함 → 격리

ADVERSARY R1 근거 반증 GASTRIC_PH: 근거 문서 ["FDA_ACID_REDUCING"] 를 코퍼스에서 찾지 못함 → 격리

ADVERSARY R1 근거 반증 THYROID: 근거 문서 미특정 를 코퍼스에서 찾지 못함 → 격리

라운드 1에서 경보가 기각·하향되자 라운드 2에서 분자특이 조항이 1종→0종으로 줄고 수렴했다. 기권을 100%가 감지되자 임계를 낮추는 대신 사람에게 계약 개정을 요청했다.

주지표 FOR_safety

0.12%

목표 2% 이하 통과
[0.02%, 0.68%]

CYP·DDI 정밀도 lift

3.56x

[2.23, 5.25]
신뢰구간이 1을 넘지 않음

QT·심전도 lift

2.93x

[1.57, 4.76]
유의하지 않음 — 주장 안 함

음성 대조 발행률

0.0000

확증 경보 없는 6,748쌍
누출 0건

집계 지표의 함정을 우리가 먼저 밝힌다. 전체를 풀링한 '발행분 정밀도÷유병률'은 0.91배로 나와 시스템이 나쁜 것처럼 보인다. 이는 **심슨의 역설**이다 — 조항별 기저율이 3배 넘게 차이나는데(간기능 0.385 vs CYP 0.101) 시스템은 기저율 높은 조항을 거의 발행하지 않기 때문이다. 그래서 **조항별 lift와 신뢰구간**을 주지표로 쓰고, 발행 가중 집계는 3.33배다.

되돌아가는 화살표가 실제로 돈 로그와 E3 지표. 라벨러 수정 후 CYP·DDI와 QT 모두 신뢰구간이 1을 넘지 않는다.

■ 연관이 곧 발행 자격은 아니다 — 조항별 τ 보정

전역 임계 하나로는 조항마다 신뢰도 분포가 달라 어떤 조항은 정밀도 0으로 발행됐다. 학습 분할에서 별도 보정 분할을 떼어(평가 분할 미사용) 조항별로 **목표 정밀도 0.30을 만족하는 최소 임계**를 찾고, 없으면 발행 자체를 봉인한다. 억지로 임계를 낮추느니 "말할 자격이 없다"고 판정하는 편이 낫다.

	발행분 정밀도	오경보율	CYP·DDI lift	음식·자몽
전역 임계	0.178	0.040	2.29배	정밀도 0
조항별 보정	0.301	0.007	3.56배	발행 봉인

오경보율이 5.7배 줄었다. 봉인 사유는 뭉뚱그리지 않고 셋으로 나눠 보고한다 — 아래.

"10종 중 2종만 발행"은 서로 다른 판정을 뭉겐 표현이라 쓰지 않는다. 10종 중 5종은 확증 기전이 없어 조항 후보가 애초에 기안되지 않는다(기전 게이트 상류에서 걸린 것이지 τ 가 정밀도를 보고 봉인한 것이 아니다). τ 보정 대상인 나머지 5종 중 **QT·CYP 2종이 발행 자격**을 얻었고, **음식·자몽(후보 395)과 위장관(325)은 검정력이 충분한데 목표 미달** — 이것만이 진짜 "말할 자격이 없다" 판정이다. **간기능은 후보 9건으로 검정력 부족**이라 정밀도가 낮다는 증거가 아니라 판정 보류다.

■ 사전 선언 기전 게이트

사전 선언 26쌍 중 **확증 8 · 기각 15**(확증률 34.8%). 기각 중 **방향이 반대로 유의한 것**이 셋이다 — 티오펜→간기능 **0.57**($p=8.9e-28$), 마이클수용체→

간기능 0.84, 염기성아민→위산분비억제제 병용 0.79. **셋 다 교과서적 기전인데 실제 프로토콜 4만 건에서는 반대로 나왔다.**

왜 사전 선언인가. 구조 플래그 15종 × 조항 14종을 전수 검토하면 보정 후에도 기전으로 설명되지 않는 유의한 연관이 쏟아진다. 실제로 PAINS와 방향족 아민이 **피임 조항까지** 유의하게 예측했다 — 화학이 아니라 **적응증·약물계열 교락**이다. 그래서 결과를 보기 전에 가설을 선언하고 **confirmatory만 가치 주장에 쓰며, exploratory는 보고만, refuted는 실패로 적는다.** PAINS는 어세이 간섭 필터이므로 임상 조항의 기전 근거로 쓰지 않는다고 못박았다.

지표	정의	목표
ΔP@C	커버리지 C에서 정밀도 - 템플릿 베이스라인 정밀도	헤드라인
FOR_safety	실제 존재하는 안전성 조항을 '불필요'로 판정한 비율. 기권은 '모르겠다'이므로 분자에서 제외해 기권으로 지표를 속일 수 없게 했다	≤ 2%
DPR · 확증률	동일 시드 3회 실행의 DAG 해시 일치율 / 사전 선언 쌍 중 확증 비율	100% · 34.8%

모든 비율에 Wilson 95% 신뢰구간을 병기한다. FOR_safety가 2%를 넘으면 절감 주장 자체를 철회한다.

5 AI 활용 투명성 및 연구 윤리

■ AI를 연구동료로 어떻게 썼는가

주제 선정: AI가 컨셉 4종 생성 + 3인 심사 패널 비교채점, 사람이 최종 선택 (융합 분야안은 서사가 산만해 기각). 근거 조사: AI가 검색, 사람이 URL 접속으로 실재 확인(출처 불명 수치 전량 기각). 실측·구현: AI가 코드 작성, 사람이 재실행해 수치 재현 검증. 집필: 초안 생성 후 문장·수치 전수 대조(과장된 절감 주장 삭제).

작업 중 스스로 잡아 고친 오류 9건을 그대로 공개한다(라벨러 결함 4건은 항목 4). ① AI가 생성한 "저장소에 LICENSE 파일 있음" 허위 서술 ② **기각된 기전 (카복실산→신기능, lift 1.02)으로 조항이 발행되던 결함** ③ 재기안이 대체 경로 없이 재시도하는 착한 것 ④ 임상 성공률 출처 오귀속 ⑤ **정합성 검사가 잡아낸 자기 결함** — 안전성 조항을 근거 부재로 조용히 기권해 실무자가 검토할 기회를 잃게 만들던 것.

제안서 수치 26건을 실측 결과와 자동 대조하는 검증(verify_numbers.py)을 두었다. 실제로 도식 재생성 누락으로 기권율이 어긋난 것을 이 검증이 잡아냈다. 대화 기록·프롬프트·모델명·기각 사유는 저장소에 남긴다.

■ 윤리를 문단이 아니라 자료형으로

모든 조항은 provenance를 자료형으로 강제한다. `kind`가 `computed`가 아닌데 `url`이나 `span\_id`가 없으면 **시스템이 자동으로 격리하고 판정 가중치를 0으로 만든다**. 근거 코퍼스에는 **URL로 실재를 확인한 문서만** 담는다 (현재 6문서: ICH E14 · ICH M12 + Q&A · FDA DILI 2009 · FDA MRSD 2005 · FDA AI 2025). **코퍼스를 3→6문서로 넓히자 격리율이 100%에서 70%로 내려갔다** — 채우지 않은 자리가 시스템 동작으로 드러나고, 채우면 지표가 개선되는 것을 보인다.

■ 먹줄이 하지 않는 것

- 분자를 새로 생성하지 않는다. 입력받은 구조를 판정만 한다.
- 합성 경로를 제안하지 않고 독성을 예측했다고 말하지 않는다. 유해 물질 합성 오남용 경로가 원천적으로 없고, 산출물은 조항 필요성 추정일 뿐이다.
- 규제 판단을 대체하지 않는다. 산출물은 RA 담당자의 검토 대상 목록이며, 자기 합격 기준을 낮출 수 없다 — kill criteria 완화는 사람 서명이 필요하다.

유전독성 불순물 경보와 위험 시약 관련 hard veto는 **사람도 우회할 수 없다**. 안전성 조항의 신뢰도 미달, 규제 상충, 모달리티 범위 외는 무조건 사람에게 승격된다.

6 본선 시연 시나리오

심사위원이 보아야 할 것은 결과가 아니라 **판단이 뒤집히는 순간**이다. 3막으로 구성한다.

막	무엇을 보여주는가	심사위원이 확인하는 것
1막 연역	실제 공개 임상시험의 SMILES를 입력한다. 좌측에 구조 경보, 우측에 조항 후보가 템플릿 기저 확률과 함께 쌓인다.	숫자가 결정론 도구에서 나온다는 것. LLM이 만진 곳은 회색으로 표시된다.
2막 반증	ADVERSARY가 돌면서 조항이 실시간으로 지워진다 . $\Delta^* \leq 0$, 근거 span 부재, 모집 인구 과다 감소로 기각되는 조항을 각각 보여준다.	시스템이 자기 산출물을 죽인다는 것 . 기권이 산출물이라는 것.
3막 대조	그 시험의 실제 선정·제외기준 원문을 나란히 띄운다. 맞힌 조항·농친 조항·헛발질한 조항을 색으로 구분하고 틀린 것을 화면에 남긴다 .	정답 대비 성능. 실패를 감추지 않는다는 것.

이 화면은 이미 만들었다. 실행 결과 JSON 하나를 받아 자기완결 HTML 한 장을 생성하며, **외부 CDN·스크립트 없이 열려 폐쇄망에서 그대로 쓴다** (`inkline/viewer.py`). 위 3막이 각각 카드로 렌더링되고, 되돌아간 경로는 붉은 좌측선으로 표시된다. 저장소의 `results/runs/\*.html`이 실물이다.

사고 과정의 시각화는 감사 DAG를 그대로 렌더링한다. 노드는 도구 호출, 엣지는 데이터 의존, 색은 결정론/LLM, 붉은 엣지는 되돌아간 경로다. 같은 시드로 다시 돌리면 **같은 DAG 해시가 나오는 것을 현장에서 보여준다**. 재현성을 말이 아니라 해시로 증명한다.

마지막 30초에는 **실패 카탈로그**를 띄운다. 티오펜 가설이 반대로 나온 사례를 포함해, 우리가 틀렸던 것을 우리가 먼저 보여준다.

7 API 및 GPU 관련 예상 소요 규모

결정론 코어가 무거운 일을 하므로 LLM 호출은 얇다. 아래는 조항당 실측 기반 추정이며 산출식을 그대로 공개한다.

텍스트→구조화 추출 프로토콜당 입력 8K·출력 2K 토큰(시험 500건 × 라운드 3) 약 6M · 조항 추출과 상충 서술 약 6M · 평가 하네스 3회 재실행(재현성 검증) 약 4M → 4주 누적 약 16M 토큰. 여유율 30% 포함.

■ GPU

예선 파이프라인은 **GPU가 필요 없다**. RDKit·scipy 기반 결정론 연산이며 39,379건 전수 분석이 CPU 4코어에서 수 분 내에 끝난다. 본선에서 GPU를 쓰는 지점은 하나다 — **Boltz-2 기반 off-target(hERG) 구조 예측**으로, 후보 20~30건에 대해 A100 기준 누적 **약 20~30 GPU·시간**을 추정한다. 이 항목은 축소 순서 1순위이며, 빠져도 시스템의 핵심 주장은 성립한다.

리소스 효율이 곧 설계 원칙이다. 숫자를 LLM에게 시키지 않아 토큰이 적게 들고, 기권 기재 덕에 확신 없는 조항에 추론을 낭비하지 않는다. 조항당 토큰과 wall-clock을 실측해 보고한다.

8 에이전트 도입에 따른 파급효과

프로토콜 수정 1건의 직접비는 2상 US\$141,000, 3상 US\$535,000이다. 그러나 **이 금액을 우리 절감액으로 청구하지 않는다**. 수정 유발 요인에는 모집 난항·신규 안전성 정보·규제기관 요청이 포함되며 구조에서 연역되지 않는다. **하류 원가의 크기를 보여주는 앵커로만 쓴다**.

[실측] 검토 대상 축소 — 기권을 92%. 대부분이 템플릿임을 데이터로 분리해 분자 특이 조항에만 집중하게 한다. [실측] 누락 조항 조기 발견 — 발행분 정밀도 lift **CYP·DDI 3.56배** [2.23,5.25], **QT 2.93배** [1.57,4.76] — 둘 다 신뢰구간이 1을 넘지 않는다. 오경보율 0.007. [실측] 검토 물량 절감 — 같은 수의 실제 조항을 찾기까지 **검토량 30% 절감**(정밀도 0.216→0.309에서 직접 유도, 추정 아님).

검토 시간(조항 200~400개 × 3분 = 10~20시간/라운드)은 추정이며 본선 사용자 스튜디오 실측 대체한다. IND 보완은 사유별 공개 통계가 없어 발생률을 수치화하지 않는다.

도입 경로 — 1단계 기존 프로토콜 검수(사후 진단) → 2단계 초안 작성 시 조항 제안 → 3단계 제출 패키지에 COU 카드·감사 DAG 첨부. 1단계는 폐쇄망에서 즉시 가능하며 국내 중소 바이오텍의 실제 진입점이다.

산업 경쟁력 기여는 방법론이다. 비결정적 멀티에이전트를 규제 환경에서 쓰려면 COU 정의와 재현성 입증에 필요한데 현재 그 방법이 없다. 먹줄의 **조항 단위 COU 카드와 감사 DAG 해시**는 다른 규제과학 에이전트에 그대로 이식 가능한 형식이다.

참고문헌 (URL 접속으로 실재 확인, 확인일 2026-07-26)

[1] Getz et al. The Impact of Protocol Amendments on Clinical Trial Performance and Cost. Ther Innov Regul Sci. doi 10.1177/2168479016632271 · [2] Chen et al. TrialBench: Multi-Modal AI-Ready Datasets for Clinical Trial Prediction. Scientific Data 2025. s41597-025-05680-8 · [3] Mitchener et al. BixBench. arXiv:2503.00096 · [4] Das et al. AMEND++. arXiv:2601.06300 · [5] FDA. Considerations for the Use of AI to Support Regulatory Decision-Making for Drug and Biological Products. Draft Guidance 2025-01 · [6] 식품의약품안전처. 의약품 개발 시 AI 활용 안내서 / 2026년 주요업무 추진계획 · [7] 한국보건산업진흥원 제약산업정보포털. 미국내 임상성공률 10년간 7.9%, 30%가 2상에서 중단 (한국바이오협회·Biomedtracker 2011-2020 분석 재인용) · [8] Schrag et al. CiteME. arXiv:2407.12861 · [9] Schmidgall et al. AgentClinic. arXiv:2405.07960